IT WILL 주영아 강사

데이터 분석 프로젝트 계획 보고서

조 / 이름	**JJ브라더 / 김정우, 안재원**
제출일	2026. 08. 26
데이터셋 이름	Wholesale customers data
캐글 URL	https://archive.ics.uci.edu/dataset/292/wholesale+customers

1. 어떤 데이터인가

원본 출처	**Archive_icu_edu 출처**
데이터 크기	440 행 × 8 열
파일 구성	Wholesale customers data.csv

"연간 구매액"인데 어느 연도인지 원본 설명에 없습니다.
양식에 없는 정보이더라도 분석에 필요한 정보 이므로 추가하도록 합시다.

2. 해당 데이터 선택 이유

- **계기** : 마케팅 분야 취업 희망하여, 마케팅으로 취업을 했을 때 실무에서 사용하는 분석방법론(군집분석-페르소나)을 채택하였고, 52기 포트폴리오를 재현하고자 합니다.
- **비교한 다른 데이터셋 후보**

후보 데이터셋	제외한 이유
Customer Shopping Dataset - Retail Sales Data	코호트분석을 진행하려 했으나, 페르소나 분석으로 변경하여 제외하였습니다.

52기 포트폴리오를 재현"은 그대로 두되, 차별점 한 줄이 필요합니다 (가장 중요)
재현 자체는 좋은 학습 전략입니다. 다만 최종 프로젝트는 "따라 했다"로 끝나면 안 됩니다.
→ 예시 — "군집 개수 결정 근거를 실루엣까지 확장",
"채널 예측 모형을 추가", "오분류 고객을 마케팅 타깃으로 재해석" 등

3. 무엇을 분석할 것인가

- **한 문장 요약**: 신규 고객의 구매 데이터만으로, 판매채널을 예측합니다.
- **핵심 질문**:
  - 도매유통 고객 데이터를 기반으로 페르소나를 도출했을 때, 각 페르소나는 어떤 판매 채널을 선호하며 이를 예측하는 모형을 어떻게 구축할 수 있는가?
- **문제 유형**: ☐ 회귀 ■ 분류 ■ 군집 ☐ 시계열
- **목표변수 Y**: 컬럼명 `Channel` / 척도 명목형
- **설명변수 X 표**

표 제목이 "설명변수 X 표"인데 첫 행에 목표변수 Channel이 들어 있습니다.
→ Y는 표 위에 따로 적고, X 표에는 6개만 남기세요.

컬럼명	의미 · 단위	Y와 관련 있다고 보는 이유
Channel	유통채널(Horica:0, Retail:1)	Y종속변수
Fresh	신선식품 연간 구매액	-
Milk	유제품 연간 구매액	-
Grocery	식료품 연간 구매액	-

지금 상태로는 서로 다른 프로젝트 두개처럼 보입니다. 각 단계와 역할을 다음과 같이 묶으세요.
(아래 내용을 그대로 사용하셔도 됩니다.)

1단계(군집) — 6개 구매액으로 고객을 N개 페르소나로 나눈다.
답하는 질문: "이 도매업체 고객은 몇 종류인가?"

2단계(분류) — 구매 패턴으로 신규 고객의 채널(Horeca/Retail)을 맞힌다.
답하는 질문: "채널 정보 없이도 구분할 수 있는가?"

3단계(연결) — 각 페르소나가 어느 채널에 몰려 있는지 교차표로 확인
→ 마케팅 시사점.

재제출 필요

주제 자체는 좋습니다. 마케팅 취업이라는 목표와 페르소나 분석이라는 방법이 잘 맞고,
데이터도 깨끗합니다.
다만 지금 계획서대로 3주를 가면 "군집이 곧 판매채널이더라" 라는
뻔한 결론에 도착합니다.
시작 전에 분석 설계 한 가지와 문서 사실오류 몇 가지만 정리 후 다시 제출 바랍니다.

Frozen	냉동식품 연간 구매액	-
Detergents_Paper	세제 및 종이류 연간 구매액	-
Delicassen	즉석/가공식품 연간 구매액	-

> 화폐 단위는 monetary init으로 미제공

> Y와 관련있다고 보는 이유는 페르소나 분석(비지도학습)으로, 연관성을 현재로서는 입증하기 어렵습니다.

> Region (지역 - Lisbon:0, Oporto:1, Other:2) 컬럼은 분석주제와 연관없으므로, 분석 대상에서 제거하려고합니다.

4. 데이터 실물 확인

행 × 열	결측 많은 컬럼	이상한 값	Y 분포
440 x 8	결측치 없음	이상한 값 없음	명목형(Horica:0, Retail:1)

다음 페이지....

- Y 분포가 무엇을 뜻하는지 몰라서, 데이터 형태로만 작성하였습니다.

5. 수행 계획

- **1주차** | 데이터 구조점검 및 전처리 & 탐색적 데이터 분석
  - 데이터 구조 점검
  - 데이터 품질 점검
  - 기술통계량 확인
  - 시각화
  - 추론통계
  - 가설 생성
- **2주차** | 모델링용 데이터 전처리 & 모델 구축 & 모델 평가 및 개선
  - 통계적 기법 활용
  - 머신러닝 기법 활용
- **3주차** | 결과 해석 및 활용
  - 결과 해석
  - 한계점 도출
  - 활용방안 제안

Y 분포 = 목표변수의 각 값이 몇 건씩 있는가
데이터 형태(명목형)를 묻는 게 아니라 개수와 비율을 묻는 항목

X 표의 "Y와 관련 있다고 보는 이유"가 전부 비어 있습니다.
계획 단계에서 요구하는 건 통계적 입증이 아니라 도메인 추론입니다.
"왜 그럴 것 같은가"를 상식 수준으로 적으면 됩니다.
이 칸이 곧 1주차 가설이 되고, 검정 결과와 맞춰 보는 재미가 여기서 나옵니다.

Y와 관련 있다고 보는 이유 (예시)
- Fresh : 호텔·식당·카페는 조리용 신선식품을 매일 씀 → Horeca에서 높을 것
- Milk : 카페 음료·소매점 진열 양쪽에서 쓰임 → 방향 불확실, 확인 필요
- Grocery : 소매점은 되팔 상품을 대량 매입 → Retail에서 높을 것
- Frozen : 식당의 보관·조리 편의 → Horeca에서 높을 것
- Detergents_Paper : 소매점의 진열·판매 상품 (식당은 자체 소모품만)
  → Retail에서 크게 높을 것
- Delicassen : 즉석식품은 소매 진열 품목 → Retail이 다소 높을 것

[Channel]
보고서 표기: Horica: 0, Retail: 1
실제 값 : Horeca: 1, Retail: 2

[Region]
보고서 표기: Lisbon: 0, Oporto: 1, Other:
실제 값 : Lisbon: 1, Oporto: 2, Other: 3

철자 틀린 부분 Horica ---> Horeca (Hotel/Restaurant/Café의 약자)

제거 근거가 약합니다. 페르소나 분석에서 지역은 보통 핵심 축입니다.

실제로 쓸 만한 근거 (제가 확인한 값):
Region 분포가 Other 316건(71.8%) 로 크게 쏠려 있음 (Lisbon 77, Oporto 47)
→ "한쪽으로 쏠려 집단 비교가 어려움"이 정확한 제거 사유입니다.
→ 지우기 전에 Channel × Region 교차표 한 번만 그려 보고, 그 결과를 근거로 제거했다고 문서에 남기세요.

"이상한 값 없음"은 사실과 다릅니다.
이 데이터는 극단적으로 한쪽으로 치우친 것으로 유명합니다.

변수	중앙값	최댓값	왜도(치우친 정도)	IQR 기준 이상치
`Fresh`	8,504	**112,151**	2.56	20건 (4.5%)
`Milk`	3,627	73,498	4.05	28건 (6.4%)
`Grocery`	4,756	92,780	3.59	24건 (5.5%)
`Frozen`	1,526	60,869	**5.91**	43건 (9.8%)
`Detergents_Paper`	816	40,827	3.63	30건 (6.8%)
`Delicassen`	966	47,943	**11.15**	27건 (6.1%)

한 개 이상 이상치를 가진 행: 108건 (전체의 24.5%)

군집분석(K-평균)은 거리로 묶는 방법입니다. 값이 큰 소수가 군집 중심을 통째로 끌고 갑니다.
실제로 아무 처리 없이 k=2를 돌리면 → 65명 : 375명으로 쪼개지고, 사실상 "Fresh 큰손 vs 나머지"가 됩니다. 페르소나가 아닙니다.

판단을 이렇게 바꿔 적으세요: "명백한 입력 오류는 없음. 단 왜도가 매우 크므로 삭제하지 않고 로그변환 + 표준화로 처리한다."

이상치를 지우지 마세요. 이 데이터의 큰 값은 오류가 아니라 "대형 거래처"라는 진짜 정보입니다.