우선은 실무적 시계열 분석으로 설계 방향을 바꾸는 것과 관련된 피드백만 제시합니다.
분석 설계를 수정해서 다시 제출하세요. 추가 피드백은 그 후에 제시합니다.

데이터 분석 프로젝트 계획 보고서

조 / 이름	**안재원**
제출일	2026. 09. 18
데이터셋 이름	power_system_load_dataset.csv
URL	전력수요량 : https://www.data.go.kr/data/15065266/fileData.do 기온 : https://data.kma.go.kr/cmmn/main.do

1. 어떤 데이터인가

원본 출처	**공공데이터포털의 한국전력거래소 전력수요량, 기상청데이터포털의 전국 기온**
데이터 크기	병합 4748행 × 3열
파일 구성	한국전력거래소_시간별 전국 전력수요량_20201231.csv (2013년~2020년) 한국전력거래소_시간별 전국 전력수요량_20211231.csv`` 한국전력거래소_시간별 전국 전력수요량_20221231.csv`` 한국전력거래소_시간별 전국 전력수요량_20232231.csv`` 한국전력거래소_시간별 전국 전력수요량_20241231.csv`` 한국전력거래소_시간별 전국 전력수요량_20251231.csv`` extremum_20260917160806.csv (기온데이터)

2. 왜 이 데이터인가

- **계기** (2~3문장): 시계열 분석에 대해 공부와 추후 본인 전공(환경)과 연관되어 취업쪽으로도 이점이 있어서 하게 되었고, 시계열 분석을 통해 피크수요 시간대를 예측하고, 전력수요가 확산후 수요 방향성을 제시하고 싶다.
- **비교한 다른 데이터셋 후보**

후보 데이터셋	제외한 이유
PowerLoad_Dataset.csv	시계열이 불규칙함
power_system_load_dataset.csv	데이터가 2022~2023년으로 트렌드를 보기 힘듬

3. 무엇을 분석할 것인가

- **한 문장 요약**: 과거 전력수요와 시간대·계절패턴을 이용하여 시간 단위 전력수요를 예측하고, 확인 후 수요 방향성 제시
- **핵심 질문**: 일별 전력수요량은 언제 피크가 발생하며, 이 패턴을 근거로 어떤 수요관리 방향성을 제안할 수 있는가?
- **문제 유형**: □ 시계열
- **목표변수 Y**: 컬럼명 전력수요량(MW/d) / 단위: MW(일 총사용량, sum기준) / 척도: 연속형
- **설명변수 X 표**

사용 컬럼

다음 페이지...

IT WILL 주영아 강사

이번 피드백은 분석 설계를 바꾸는 요청입니다.
계획서에 적으신 ARIMA 중심의 시계열 분석을 시차 파생변수를 넣은 회귀·머신러닝 모델링으로 바꾸세요.
그 이유와 방법을 문항마다 풀어 두었으니 순서대로 읽고 계획서를 고쳐 다시 제출하세요.

4748행은 2013-01-01부터 2025-12-31까지 13년치 일수와 정확히 맞습니다(윤일 3일 포함).
하루도 빠지지 않고 병합됐다는 뜻이니 이 사실을 문장으로 적어 두세요.
다만 3열은 너무 적습니다.
"시간별 → 일별"로 합칠 때 합계(sum) 하나만 만들지 말고 최대(max)와 최대가 나온 시각(hour)도 같이 만드세요. 왜 필요한지는 뒤에서 설명합니다.

파일명이 extremum(극값)이면 평균이 아니라 최고·최저기온 자료일 가능성이 큽니다. 열 이름을 확인하고 평균·최고·최저 세 개를 모두 받아 오세요.
그리고 "전국 기온"을 어떻게 만들었는지(기상청의 전국 평균 옵션인지, 특정 지점인지) 한 줄 적어 주세요.
여름 전력 피크는 "그날 얼마나 더웠나"가 아니라 "가장 더운 순간이 몇 도였나"에 붙어 갑니다. 하루 평균 28도인 날과, 평균은 같지만 낮 최고가 36도인 날은 에어컨 가동량이 다릅니다.
평균 하나로는 이 차이를 못 잡습니다.

이 문장이 계획서 전체와 부딪힙니다. 시간대를 예측하려면 시간별 자료가 있어야 하는데, 1절에서 일 단위로 합쳐 버리셨습니다. 3절의 목표변수를 바꾸면서 이 문장도 같이 맞추세요

시계열을 공부하겠다는 목적이라면 ARIMA 하나만 배우고 끝내지 마세요.
실무에서 시계열 예측은 대부분 시계열을 회귀 문제로 바꿔서 푸는데,
이 방법을 이번 프로젝트의 중심으로 삼기 바랍니다. 방법은 다음 페이지에서 제시합니다.

check

공휴일 달력을 추가하세요.
파이썬 holidays 패키지의 holidays.KR(years=range(2013, 2026))
한 줄이면 설·추석·대체공휴일까지 나옵니다.
전력수요에서 기온 다음으로 큰 변수입니다

Y를 일 최대전력(MW)으로 바꾸세요. 시간별 24개 값 중 가장 큰 값입니다.

단위로 명시한 MW/d 는 없는 단위 입니다. 시간별 MW를 24시간 더하면 MWh가 됩니다. 합계를 쓰신다면 단위를 MWh로, 최대를 쓰신다면 MW로 적으세요.

핵심 질문의 "일별 전력수요량은 언제 피크가 발생하며"에서 ""언제""가 날짜인지 시각인지 모호합니다.
Y를 일 최대전력으로 바꾸면 질문은 이렇게 됩니다.

--> "어떤 날(기온·요일·휴일 조건)에 일 최대전력이 얼마나 커지는가를 하루 전에 예측하고, 그 조건을 근거로 수요관리 시점을 제안한다"

이에 따라 한 문장 요약의 "시간 단위 전력수요를 예측" 부분도 시간 단위를 빼고 수정하는 것이 좋겠습니다.

check

* MW와 MWh의 차이점

- MW는 어느 순간에 전기를 쓰는 세기, 즉 전력이고 MWh는 그 세기로 한 시간 동안 쓴 양, 즉 전력량입니다.
- 시간별 자료에 적힌 값은 그 시간의 평균 전력(MW)이고, 24개를 더하면 하루 동안 쓴 전력량(MWh)이 됩니다. 전력을 24번 더한다고 전력이 되지는 않습니다.

* 합계가 아니라 최대가 필요한 이유

- 발전 설비와 송전망은 하루에 쓴 총량이 아니라 가장 많이 쓰는 순간에 맞춰 준비돼 있어야 합니다.
- 그 순간을 넘기면 공급 부족이 생기기 때문입니다.
- 계획서에 쓰신 "피크수요", ""수요관리 방향성""은 전부 최대전력 이야기입니다.
- 합계를 예측하면 정작 하고 싶은 질문에 답이 안 나옵니다.

* 피크 시간대 산출 방법

- 1절에서 만들어 둔 "최대가 나온 시각(hour)" 열로 답합니다.
- 계절별·요일별로 이 시각의 분포를 그리면 "여름은 오후 3시 전후, 겨울은 오전 10시와 저녁 6시 전후" 같은 문장이 EDA에서 바로 나옵니다.
- 모델링 없이 1주차에 끝낼 수 있는 질문입니다.

check

문제 유형을 회귀로 바꾸세요.

시계열 자료를 쓰지만 푸는 방법은 회귀와 머신러닝입니다

지금까지의 내용을 정리하면 분석목표를 "하루 전에 다음 날 일 최대전력을 예측한다" 로 못 박을 수 있습니다.
이 한 줄이 없으면 어떤 시차 변수를 써도 되는지 정할 수 없습니다

* 시계열을 회귀 문제로 바꾸는 방법
- 내일 전력수요를 예측할 때 가장 유용한 정보는 오늘 값과 지난주 같은 요일 값입니다.
- 이 두 값을 각 행의 새 열로 만들어 붙이면, 표는 "X 몇 개로 Y 하나를 예측하는" 보통의 회귀 문제가 됩니다.
- 이렇게 과거 값을 열로 옮겨 만든 변수를 시차 변수(lag) 라고 부릅니다.

* 이 방식을 사용하는 이유

- 첫째, 한번 시차 변수를 선형회귀·Ridge·랜덤포레스트·XGBOOST 어떤 모델이든 같은 표에 넣어 비교할 수 있습니다. 계획서에 쓰신 XGBOOST도 시차 변수가 있어야 비로소 시계열에 쓸 수 있습니다.
- 둘째, 기온·요일·공휴일 같은 외부 변수를 그냥 열로 추가하면 됩니다. ARIMA는 이런 변수를 넣기가 까다롭습니다.

* 예측 시점의 중요성

- 며칠 앞을 예측하느냐에 따라 쓸 수 있는 시차 변수가 달라집니다.
- 내일을 예측할 때는 오늘 값을 쓸 수 있지만 7일 뒤를 예측할 때는 6일 뒤 값을 아직 모르니 쓸 수 없습니다.
- ""하루 전 예측""으로 정하면 1일 전 값부터 전부 쓸 수 있습니다.

컬럼명	의미	단위	Y와 관련 있다고 보는 이유
일시	날짜	datetime	시계열 축
기온	일 평균기온	℃ (연속형)	기온(여름/겨울)에 따라 전력수요량피크가 일어남

지금 표에는 일시와 기온 두 줄뿐입니다.
다음 페이지의 표를 참고해 계획서 양식에 맞게 다시 작성하세요.
"Y와 관련 있다고 보는 이유"는 2주차 결과와 대조할 가설이니 한 줄씩 꼭 채우세요.

4. 데이터 실물 확인

행 × 열	결측 많은 컬럼	이상한 값	
4748 x 3	결측치 없음	전력수요량(MW/d) 에사 하한이상치(8건) 및 상한이상치(5건)	

날짜를 확인해 보세요.
하한 8건은 거의 확실히 설·추석 명절 연휴이고 상한 5건은 폭염일입니다.
오류가 아니라 이 데이터에서 가장 중요한 현상입니다.
"이상치 13건"이 아니라 "명절 8일, 폭염 5일"로 표에 적어야 합니다.

5. 수행 계획

- **1주차**
  - #1. 데이터 구조 및 품질점검
    - 데이터 전처리 및 병합 (한국전력거래소 연도별 파일, 기상청 데이터 병합)
    - 데이터 구조 점검
    - 자료형 변환 및 시간 인덱스 설정
    - 데이터 품질 점검 (중복,결측,시간빈도 점검)
    - 기술통계량 확인
    - 이상치 및 비정상 관측값 확인
  - #2. EDA
    - 시계열 시각화 (추세, 계절성, 주기, 변동성 확인)
    - 단변량, 이변량, 다변량 분석
    - 시계열 구조분해
    - 성상성 검정 : ADF, KPSS
    - 자기상관 및 교차상관 확인
    - Ljung-Box, Granger인과성 검정
- **2주차**
  - #3. 모델링
    - 모델링용 전처리 (파생변수 생성 : 계절, 평일여부, HDD/CDD)
    - 시간 순서 기반 데이터 분할
    - 이상치 처리 및 스케일링
    - 차분, 계절차분 및 시차,롤링 변수 점검
    - VIF 확인
    - 모델 확인 (ARIMA / SARIMA / XGBoost)
    - 기준모델 설정
    - 후보 모델 학습
    - 하이퍼 파라미터 튜닝
    - 예측 성능 평가
    - 잔차진단 (자기상관, 정상성, 등분산성 확인)
    - 최종모델 선정
  - #4. 결과 및 한계점
    - 결과 보고
    - 한계점

1년 내내 값을 한 통에 넣고 IQR을 재면 여름·겨울 값이 통째로 이상치로 잡힐 수 있습니다.
계절을 나눠서 보거나 월별·요일별 상자그림으로 확인하세요.

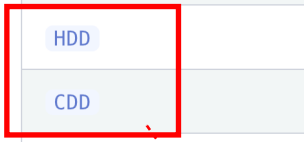
명절 당일의 낮은 값을 지우고 학습하면 모델은 명절 효과를 배우지 못하고 내년 명절에도 평일 수준을 예측합니다.

폭염일을 지우면 폭염 효과를 못 배웁니다.

명절에 뚝 떨어지고 폭염에 치솟는 것을 배우는 게 이 모델의 일이고 다음페이지에서 제시하는 표의 holiday·CDD가 바로 그 일을 하는 변수입니다.

5절 2주차의 "이상치 처리" 단계는 지우세요.

컬럼명	의미	단위	Y와 관련 있다고 보는 이유
`lag_1`	1일 전 최대전력	MW	전력수요는 하루 사이에 크게 안 변한다. 어제가 높으면 오늘도 높다
`lag_2`	2일 전 최대전력	MW	이틀 전 값이 어제 값의 흔들림을 보정한다
`lag_7`	7일 전(지난주 같은 요일) 최대전력	MW	요일 패턴이 강해서 지난주 같은 요일이 어제보다 나은 힌트일 수 있다
`lag_14`	14일 전 최대전력	MW	2주 전 같은 요일. 지난주가 연휴였을 때의 대안 힌트
`lag_364`	364일 전(작년 같은 요일) 최대전력	MW	계절성. 365가 아니라 364인 이유는 52주 전이 같은 요일이기 때문
`roll7_mean`	어제까지 최근 7일 평균	MW	최근 한 주의 수준. 하루짜리 튐을 평평하게 만든 힌트
`dow`	요일 (0~6)	범주	평일·주말 수요 차이
`month`	월	범주	계절
`holiday`	공휴일 여부	0/1	공휴일은 산업용 수요가 빠져 크게 낮다
`holiday_span`	연휴 3일 이상 여부	0/1	설·추석은 하루짜리 공휴일보다 훨씬 낮다
`bridge`	공휴일 전날·다음날	0/1	연휴 앞뒤도 조업이 줄어든다
`t_mean` , `t_max` , `t_min`	일 평균·최고·최저 기온	°C	냉난방 수요
`HDD`	max(18 − 평균기온, 0)	°C	18도보다 추운 만큼 난방을 켠다
`CDD`	max(평균기온 − 24, 0)	°C	24도보다 더운 만큼 냉방을 켠다
`t_max_lag1`	어제 최고기온	°C	더위가 이틀 이어지면 건물이 달궈져 수요가 더 는다
`year` 또는 `trend`	연도 또는 일련번호	정수	13년 동안의 완만한 증가 추세



기온과 전력수요는 직선 관계가 아니라 U자입니다.
18도 근처에서 가장 낮고 추워져도 더워져도 올라갑니다.
직선 회귀는 U자를 못 그리니, "18도보다 얼마나 추운가"(HDD)와 "24도보다 얼마나 더운가"(CDD)로 쪼개서 두 개의 직선으로 만드는 것입니다.
기준 온도 18과 24는 시작값이고, 2주차에 바꿔 가며 더 잘 맞는 값을 찾아도 됩니다.

- **3주차**
  - PPT 및 포트폴리오 작성

check

2주차 (#3 모델링) — 이 부분을 통째로 다시 쓰세요.

지금 목록에는 ARIMA용 단계(차분·정상성·스케일링)와 머신러닝용 단계(파생변수·XGBoost)가 한 줄로 섞여 있습니다.
어느 모델에 어느 단계가 필요한지 나눠야 합니다. 아래 ①~⑦ 순서로 바꾸세요.

① 모델링용 파생변수 생성

```python
import holidays

df = df.sort_values('일시').set_index('일시')
y = 'peak_mw'                                          # 일 최대전력

for k in [1, 2, 7, 14, 364]:
    df[f'lag_{k}'] = df[y].shift(k)
df['roll7_mean'] = df[y].shift(1).rolling(7).mean()    # shift(1)이 먼저

df['dow']   = df.index.dayofweek
df['month'] = df.index.month
kr = holidays.KR(years=range(2013, 2026))
df['holiday'] = df.index.map(lambda d: int(d in kr))
df['HDD'] = (18 - df['t_mean']).clip(lower=0)
df['CDD'] = (df['t_mean'] - 24).clip(lower=0)

df = df.dropna()                                       # 첫 364일은 lag_364가 비어 사라짐
```

VIF를 점검하지 마세요.

lag_1, lag_7, roll7_mean은 서로 상관이 매우 높은 변수라 VIF가 수십 이상 나옵니다.
VIF는 "계수 하나하나를 해석할 때" 문제가 되는 지표인데, 이 프로젝트의 1차 목표는 예측이라 상관없습니다.

shift(1)을 먼저 하는 이유는 이동평균에 오늘 값이 들어가면, 오늘 값을 예측하는데 오늘 값을 쓰는 셈이기 때문입니다.

예측 시점에 알 수 없는 정보가 X에 섞여 들어가는 이런 실수를 데이터 누수라고 하고 결과가 비현실적으로 좋게 나오기 때문에 발견하기도 어렵습니다.

"어제까지의 7일 평균"이 되도록 먼저 한 칸 밀고 나서 평균을 내세요.

어제 값, 지난주 값을 X로 넣은 선형회귀는 수식을 풀어 보면 AR 모형에 기온·달력을 얹은 것과 같습니다.

이름만 다르지 ARIMA와 같은 계열의 모델입니다. 그래서 이 방식으로 가면 시계열 공부를 건너뛰는 것이 아니라 시계열 모델을 회귀 형태로 다시 배우는 것입니다

② 시간 순서 분할 : 학습 2013~2023, 검증 2024, 테스트 2025
train_test_split의 무작위 섞기는 쓰지 마세요. 과거 구간으로 학습하고 미래 구간으로 평가해야 합니다.
미래 데이터가 학습에 섞여 들어가면 그것도 누수입니다.

TimeSeriesSplit을 사용해야 합니다.

TimeSeriesSplit

```
class sklearn.model_selection.TimeSeriesSplit(n_splits=5, *, max_train_size=None, test_size=None, gap=0)
```